

マエバシ精工株式会社 御中 業務最適化 提案

報告資料



株式会社マナビDX

2022/10/27(木)

目次

- § 1. 本プロジェクトの背景・目的
- § 2. 検討プロセス
- § 3. ご提案サマリー
- § 4. AIによる需要予測
- § 5. ルールベースでトラック台数予測
- § 6. 業務フローの変更
- § 7. ロードマップの策定
- § 8. 参考資料

§ 1. 本プロジェクトの背景・目的

■プロジェクトの背景

- ・ 貴社の業績は堅調に推移してきたが、直近数年でビジネス規模の拡大に舵を切り始めている。
しかし、業務プロセス自体は従来のものであったため、トラック手配や生産計画立案などの領域で、
- ・ 改善の必要性を感じている。
- ・ また、いくつかの業務が属人化しており、かつ社員の平均年齢も上がってきている。
- ・ そんな最中、世界的パンデミックの発生によりビジネス環境に大きな変化が訪れ、常に安定的にビジネスを行いつらい状況を迎えている。

■プロジェクトの目的

以下の2つの手法を用いて、トラック契約台数の最適化を本プロジェクトの目標とする。

- ① 需要予測により、トラック契約台数の最適化を見据え、AIによる需要予測モデルの可能性を検証する。
- ② ルールベースでの内示需要量からのトラック契約台数の最適化を行う。

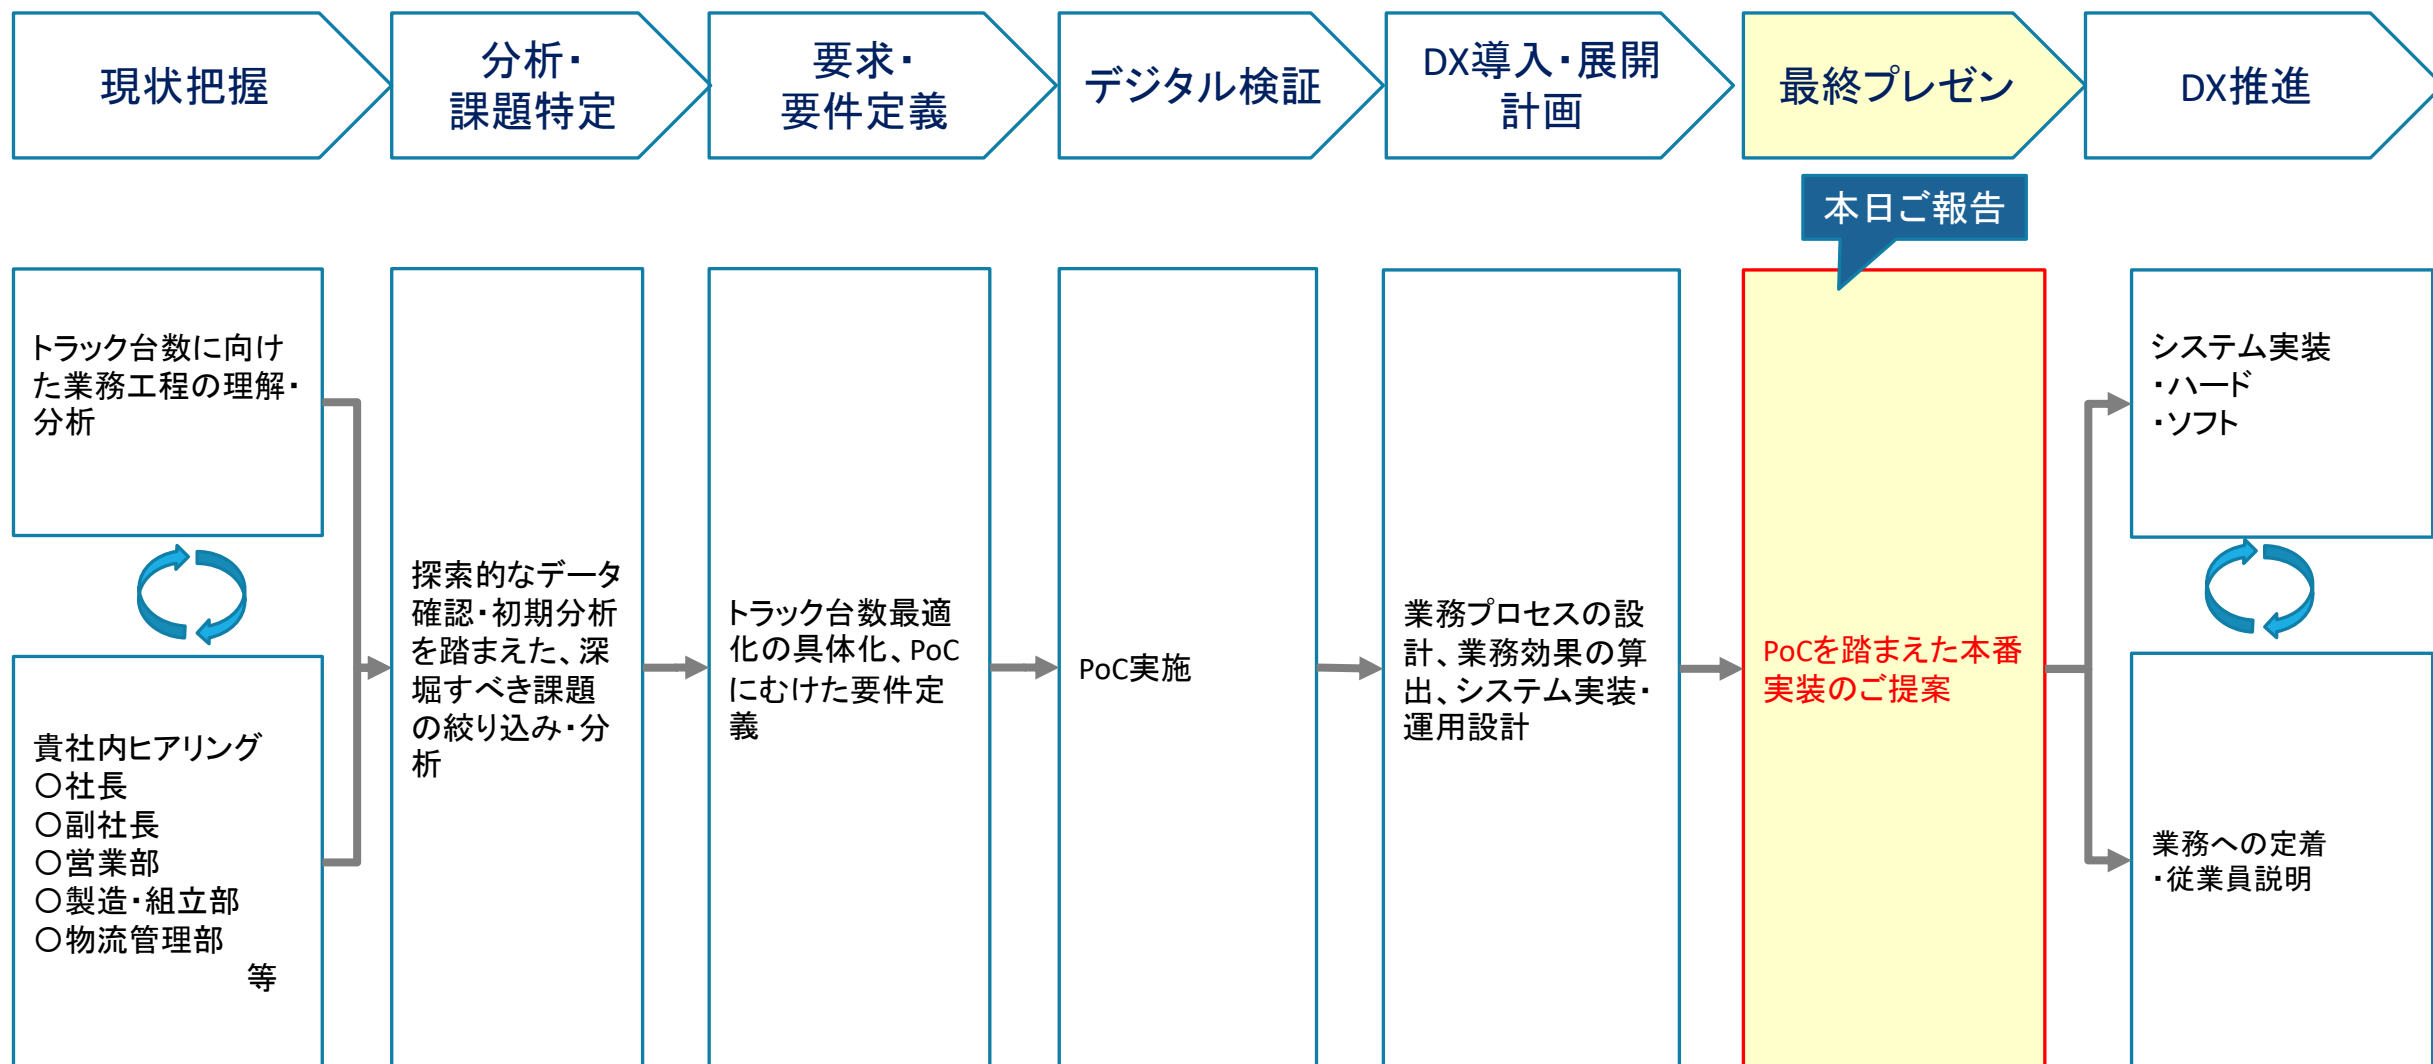
■目標の設定

トラック契約台数の最適化として以下を目標とする。

1. 現行の2カ月前内示に置き換える需要予測モデルを検討し、その需要量から必要トラック量を算出する。
2. 現行のデータ量で需要予測が行えるか、どれほどデータを蓄積すれば需要予測が可能かを検討する。
3. 現行データで需要予測が不可能となった場合、ルールベースでのトラック台数の算出を検討する。

§ 2. 検討プロセス

4



§ 3. ご提案サマリー

- ◆貴社トラック契約台数最適化に向け、需要量の大きい部品に着目したAIによる需要予測のPoCを行った。
- ◆さらにルールベースでのトラック台数算出のPoCを実施した。
- ◆本日はPoC(実証実験)結果も踏まえ、AIによる需要予測の可能性、およびルールベースでの台数予測の効果及びコスト、本番実装に向けたアクションについてご提案する。

①AIによる需要予測

- 本検討では、当該年月の前月までの最終(確定)需要量を元にAIでの需要予測を行った。
 - ・ 現行データ量では、データ不足で需要予測の精度は十分ではない。
 - ・ そこで、ダミーのデータを追加し、どの程度のデータ量であれば需要予測が可能かシミュレーションを行った。
 - ・ 結果として **4年間以上のデータ量**があれば、精度が向上しAIによる需要予測が出来る可能性はある。
 - ・ 需要予測の精度が向上出来た場合、需要予測⇒製造計画⇒在庫管理と順次展開していくことが可能となり、システムを統合していくことが可能となるので、**継続してデータ収集・検証を行い、精度向上を目指したい。**

②ルールベースでのトラック台数予測

- 現状のデータ量ではAIによる需要予測は困難である為、代替案としてルールベースでのトラック台数の予測も行った。
 - ・ 結果として、最大で200万円/月程度のトラック費用削減が可能であった。
- 初期費用を抑えたトラック台数の最適化、ランニングコスト縮小、従業員の満足度・負荷軽減が実現可能な見込み。
 - ・ 初期費用：PoCで作成したExcelを用いれば、**イニシャルコストは0。**
 - ・ 今後の継続運用が見込まれる場合は段階的にシステム化も可能。
 - ・ ランニングコスト：**一人で1H/月程度。**（新規の**データの取込作業のみ**で実行が可能）
 - ・ 従業員の満足度向上・負荷軽減：**Excelによる簡単操作**なので、担当者の満足度・帰属意識が向上。

※基本的にクラウドのSaaSサービスは利用せず、社内サーバーでの運用を想定する。

（SaaSではシステム障害発生時に、復旧まで影響が出る為。更に、クラウド化するメリットも少ないと考えられる）

§ 4. AIによる需要予測

§ 4-1. AIによる需要予測 要件定義

■分析結果のビジネスユースケース

- ・2ヶ月前内示を受領した時点で、前月末までの最終需要量から2ヶ月後の最終需要量を予測し、内示需要量と比較を行う。
- ・予測した需要量から、必要トラック台数を算出し、定期便の契約を行う。
- ・また、予測した需要量からの在庫予測や、製造計画にも展開が可能と考える。

■需要予測に使用するデータの期間




- ・学習データ:2019年3月～2021年3月までの最終需要量。
- ・評価データ:2021年4月～11月の最終受注実績。

■需要予測の対象部品

- ・部品コードの頭文字1文字(アルファベット)を部品シリーズと読み取り、部品シリーズ毎に累計需要量の多いTop3を算出し、需要予測により効果的な部品を抽出する。

§ 4-2. 予測対象部品の選定

部品コードの頭文字1文字(アルファベット)を部品シリーズと読み取り、部品シリーズ毎に累計需要量の多い**Top3**を算出し、需要予測により効果的な部品を抽出する。




※他シリーズについては[参考1]を参照

結果

- Dシリーズの部品であれば、**Top3が同様の周期性**を示している。
- 取引先コードが5999である部品コードD2502464の部品の需要予測が出来れば、部品コードD2502506,D2502392も同様の手法によって需要予測が可能と考えられる。
- 以降、部品コードD2502464の部品の需要予測を行っていく。

§ 4-3. 部品コードD2502464の内示需要量と最終需要量の比較



結果


- 毎年8月に需要が落ち込む(緑○)。盆休み等が関係していると考えられる。
- 2019年12月～2020年05月の需要量に対して、2020年12月～2021年05月の需要量が異なる。

§ 4-4. 部品コードD2502464にて現行データで需要予測を行う

10

条件

- 当月を2021年4月とし、2021年3月までの最終需要量が確定している状態で、2021年4月以降の最終需要量を予測する
- 当月以降の部品コードD2502464の需要予測を行う
- 時系列予測手法にはProphetを用いる



結果


- グラフの赤実線が最終需要量の予測を行ったものである。
- 各点線は2021年4月時点ではブラインドデータである
- データ量が少ない為、内示需要量からも大きくかけ離れた値を予測している
- **現行のデータ量**では最終需要量を正確に**予想するのは困難**である
- それでも、これだけのデータ量でも、**毎年8月の落込みや、その両端のピークの特徴(緑円)は掴めている**

§ 4-5. 部品コードD2502506の需要予測(ダミーデータ拡張)

11

条件

- 現行データでは予想が難しいので、ダミーの過去データを付加して予測を行う。
- 2019年03月～2021年2月のデータをベースに各月ランダムで±20%の範囲でデータを変動させ、4年分のダミーデータを作成した。
- 当月を2020年2月とし、2020年01月までの最終需要量が確定している状態とする。
- 2020年1月以降の部品コードD2502464の需要予測を行う。(傾向を見る為、1年程度の予想を行う)



結果

- グラフの赤実線が最終需要量の予測を行ったものである。
- オリジナルデータより**最終需要量(黒点線)**に沿う値を予測している。
- オリジナル予想と同様に、**毎年8月の落込み及び、その両端のピークの特徴は掴めている**。
- 緑○で示した、**内示より最終需要量が多い値もトレース出来ている**ので、内示量ではなく予測値に応じて定期トラックを手配することにより、**非定期便の発注回数は減らせる**と考える。一方、2021年5月以降は内示の方に引きずられている。(オレンジ○)

§ 4-6. AIによる需要予測 結果

- 現行データ量では正確な需要予測は困難と言える。
- 仮に過去4年分のデータがあった場合、需要予測の精度を向上させることが出来る可能性が示せた。
- また、予測した需要量から必要在庫数を算出し、(将来的に)在庫予測等にも展開が可能と考える。

※ここで用いた過去データは現行データを元にしたダミーデータである為、実データの傾向とは異なる。
本来のデータであれば、例年の各月の特徴を捉える事ができ、より精度を向上させることが出来ると思う。

※仮に、内示に対して予測値が小さな値を示した際は、欠品リスクがあるので内示を優先しトラック契約する。
一方、内示に対して予測値が大きな値を示した際は、先の需要量の拡大を見越し、予測を優先しトラック契約する。

今後の展望

- ・まずは、引き続き需要量のデータの蓄積を行い、毎月の2カ月先内示受領の際に本AIシステムで需要予測を行い、2ヶ月後の最終需要確定の際に予測値とどれだけ乖離しているかのデータ収集を行う。
- ・最終需要との乖離が少なくなって来たタイミングで導入検討の提案を行いたい。
- ・半年/1年といったスパンで乖離率の状況について報告を行う予定である。

※時系列予測による需要予測は現時点ではデータ不足により、データが蓄積されるまでは打つ手がないので、代替案としてルールベースのトラック台数予測の検討を進める。

§ 5. ルールベースでトラック台数予測

§ 5-1. ルールベースでトラック台数予測 要件定義

■方策

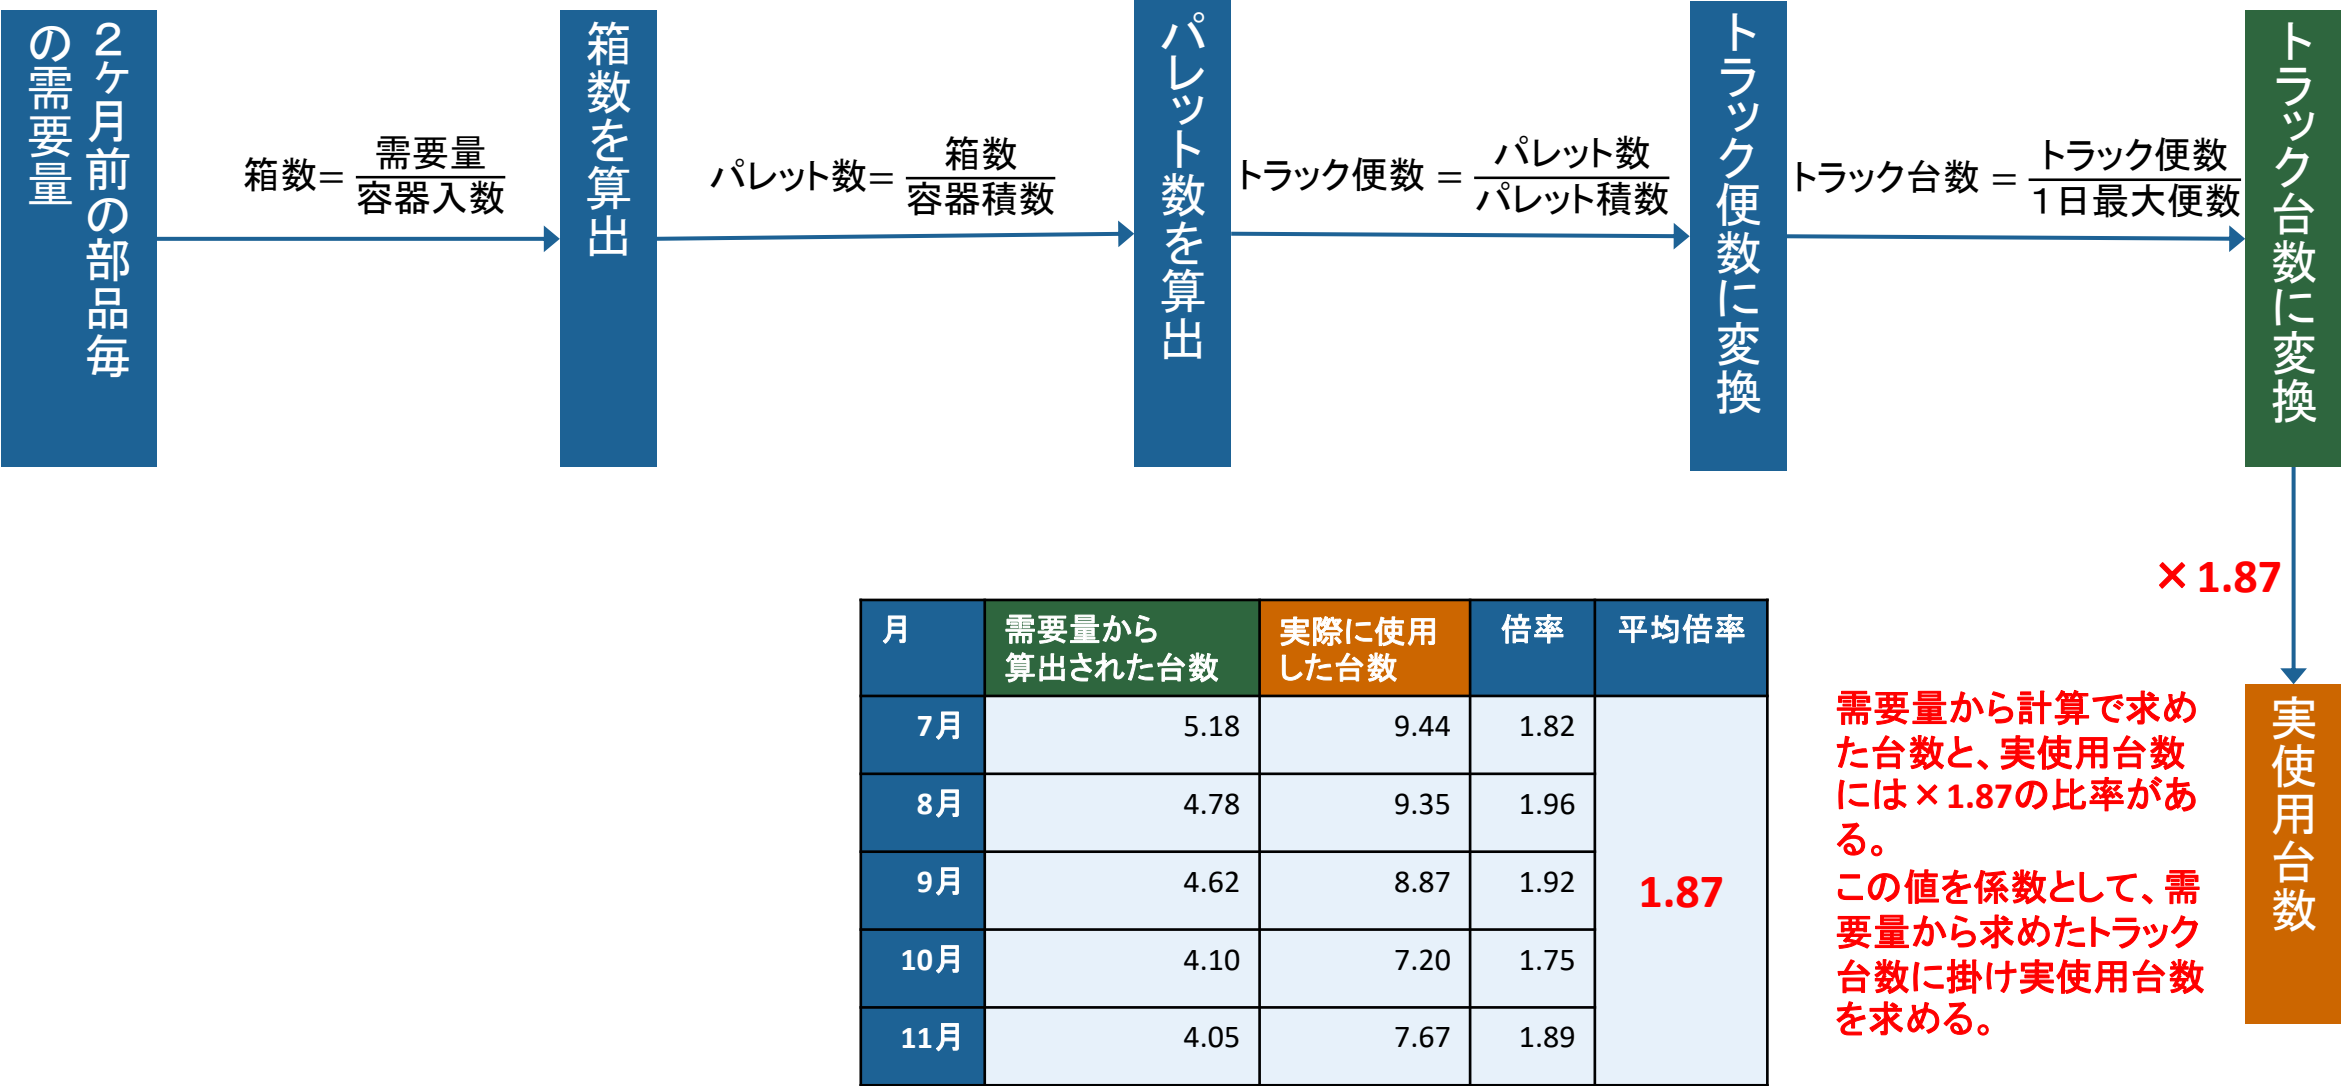
- ・定期便・非定期便の最適な契約台数を見積もるためには、日次の必要トラック台数を予測して、それを元に費用が最小になる定期便・非定期便の台数を決定するのが最良であるが、需要量データが月次データしか存在しないため、日次の必要トラック台数を算出するのは困難である。
- ・そこで月の平均使用台数分だけ定期便を契約し、そこから溢れた分は非定期便を使用するという方策をとることにし、定期便・非定期便の組み合わせにより、費用がどれくらい削減されるのかの検証を行った。

- 予測対象: 月次の平均トラック使用台数
- データ粒度: 月次予測
- 予測タイミング: 2ヶ月前(定期便の契約を行う前)
- 使用可能データ: 2ヶ月前の部品毎の内示需要量、2ヶ月前までのトラック台数など
- 実行時間: 8時間以内(1営業日内)

■手法

- ・ルールベース手法を使用する(各手法の説明/比較は[説明2]を参照)
 - メリット : データが少なくても予測可能
 - デメリット : 人間が想定したルールから外れるデータは予測が困難

§ 5-2. 需要量からトラック台数の算出方法



§ 5-3. 実使用台数と計算によって求めた台数の比較

方針

- 先程求めた実使用台数係数1.87からトラック台数を求める
- 現行の使用台数と計算によって算出した台数を比較する。

精度

- 誤差は8月のみ1台である。

月	予測台数 (※)	実際に使用した台数 (※)	誤差	実際に使用した台数に対する差分率(%) ((予測台数 - 実際に使用した台数) ÷ 実際に使用した台数) × 100
7月	10 (9.68)	10 (9.44)	0	3%
8月	9 (8.93)	10 (9.35)	+1	-4%
9月	9 (8.64)	9 (8.87)	0	-3%
10月	8 (7.67)	8 (7.20)	0	7%
11月	8 (7.58)	8 (7.67)	0	-1%

全体的に差分率は±10%以内に収まっている。

§ 5-4. 実使用台数と計算によって求めた台数の比較

シミュレーション結果

- トラック台数予測モデルの予測値を定期便の契約台数とした場合、トラック費用がどのように変化するかをシミュレーションした。

月	実際の値			計算値			差額
	定期台数	非定期便数	費用	定期台数	非定期便数	費用	
7月	10	13	18,567,000	10	13	18,567,000	0
8月	10	2	12,051,000	9	16	12,038,700	-12,300
9月	10	1	16,161,000	9	19	16,065,300	-95,700
10月	10	0	16,077,000	8	12	13,869,600	-2,207,400
11月	10	0	16,077,000	8	12.5	13,911,600	-2,165,400

結論

- シミュレーションの結果、予測モデルを使用した場合 現状よりも費用が増加することではなく、最大で1ヶ月に**2,207,400円**の**費用削減**が見込めることが分かった。
- また、今回の予測モデルを使用すれば、トラック費用だけでなく、従来予測にかかっていた**8～16時間分の工数も削減**できる。

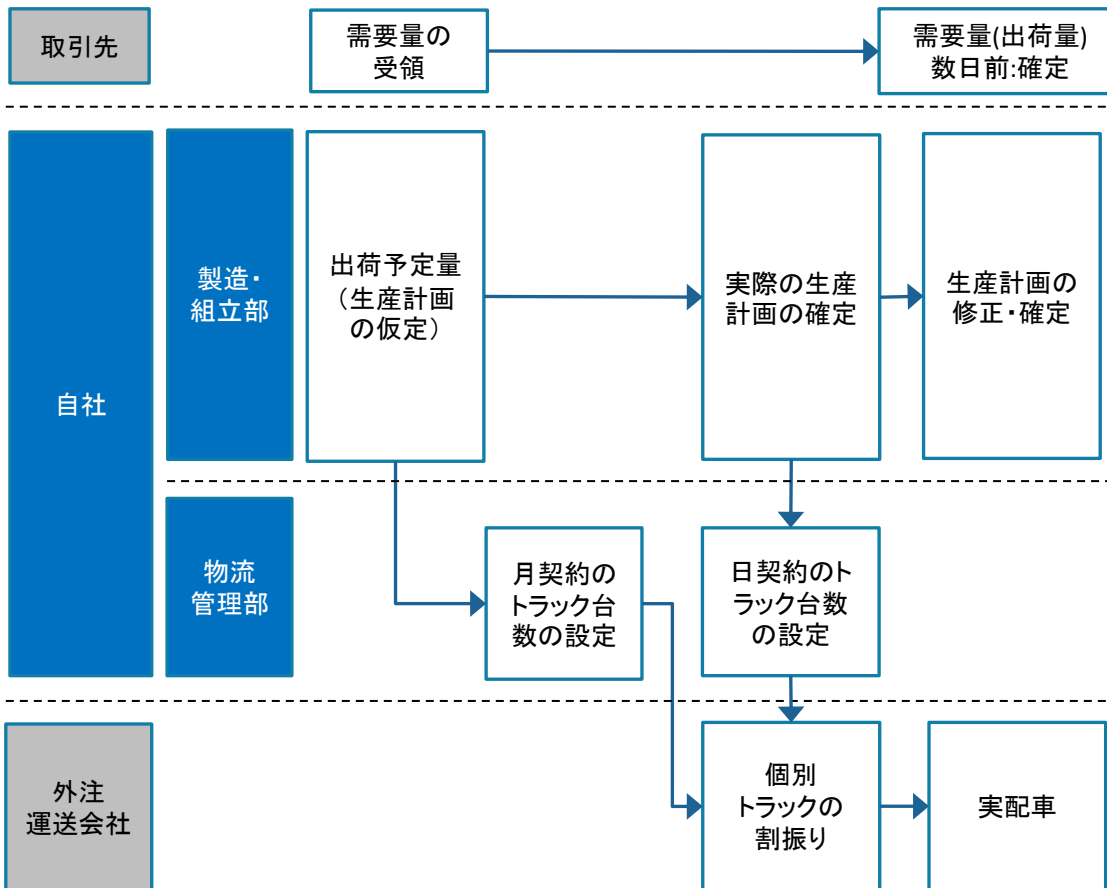


§ 6. 業務フローの変更

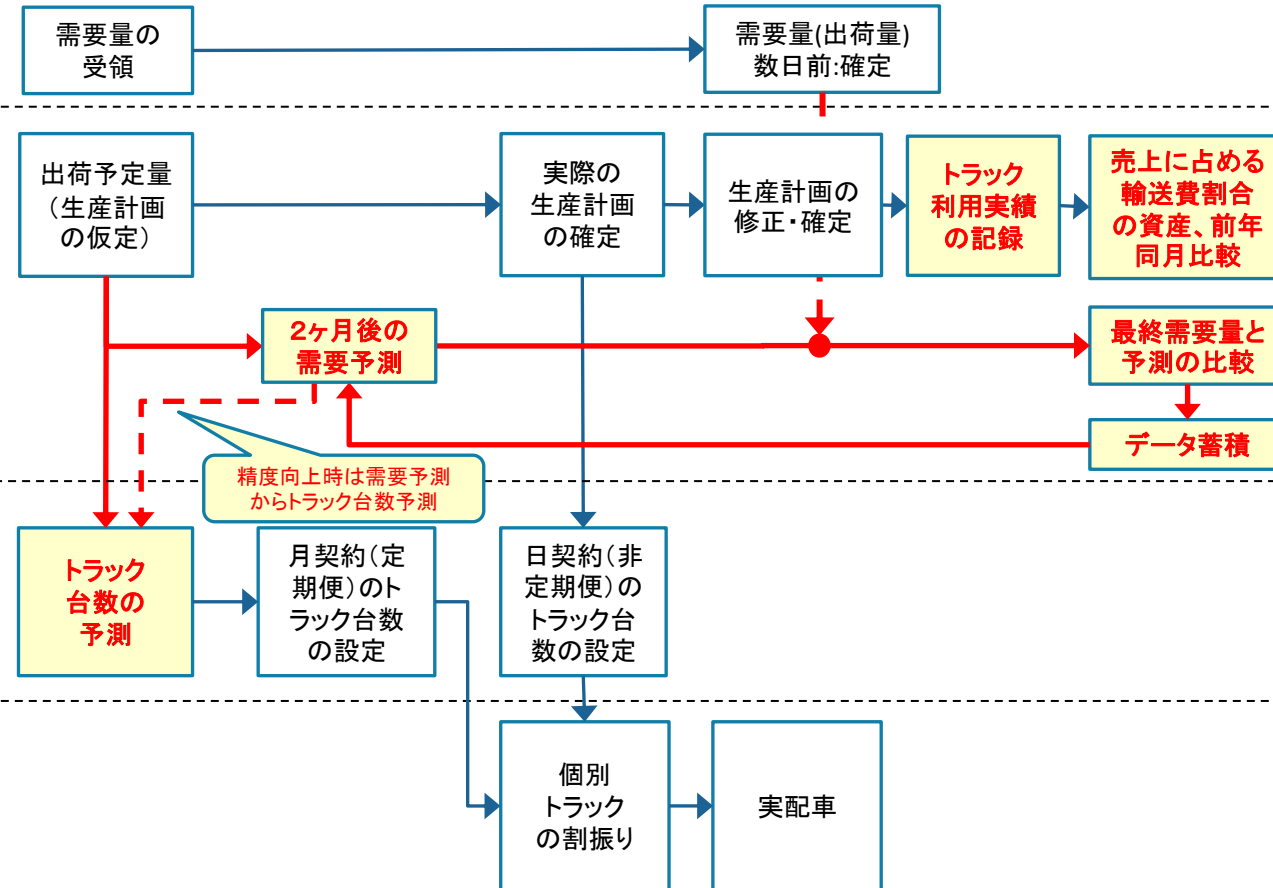
§ 6. 業務フローの変更

19

現状



変更後

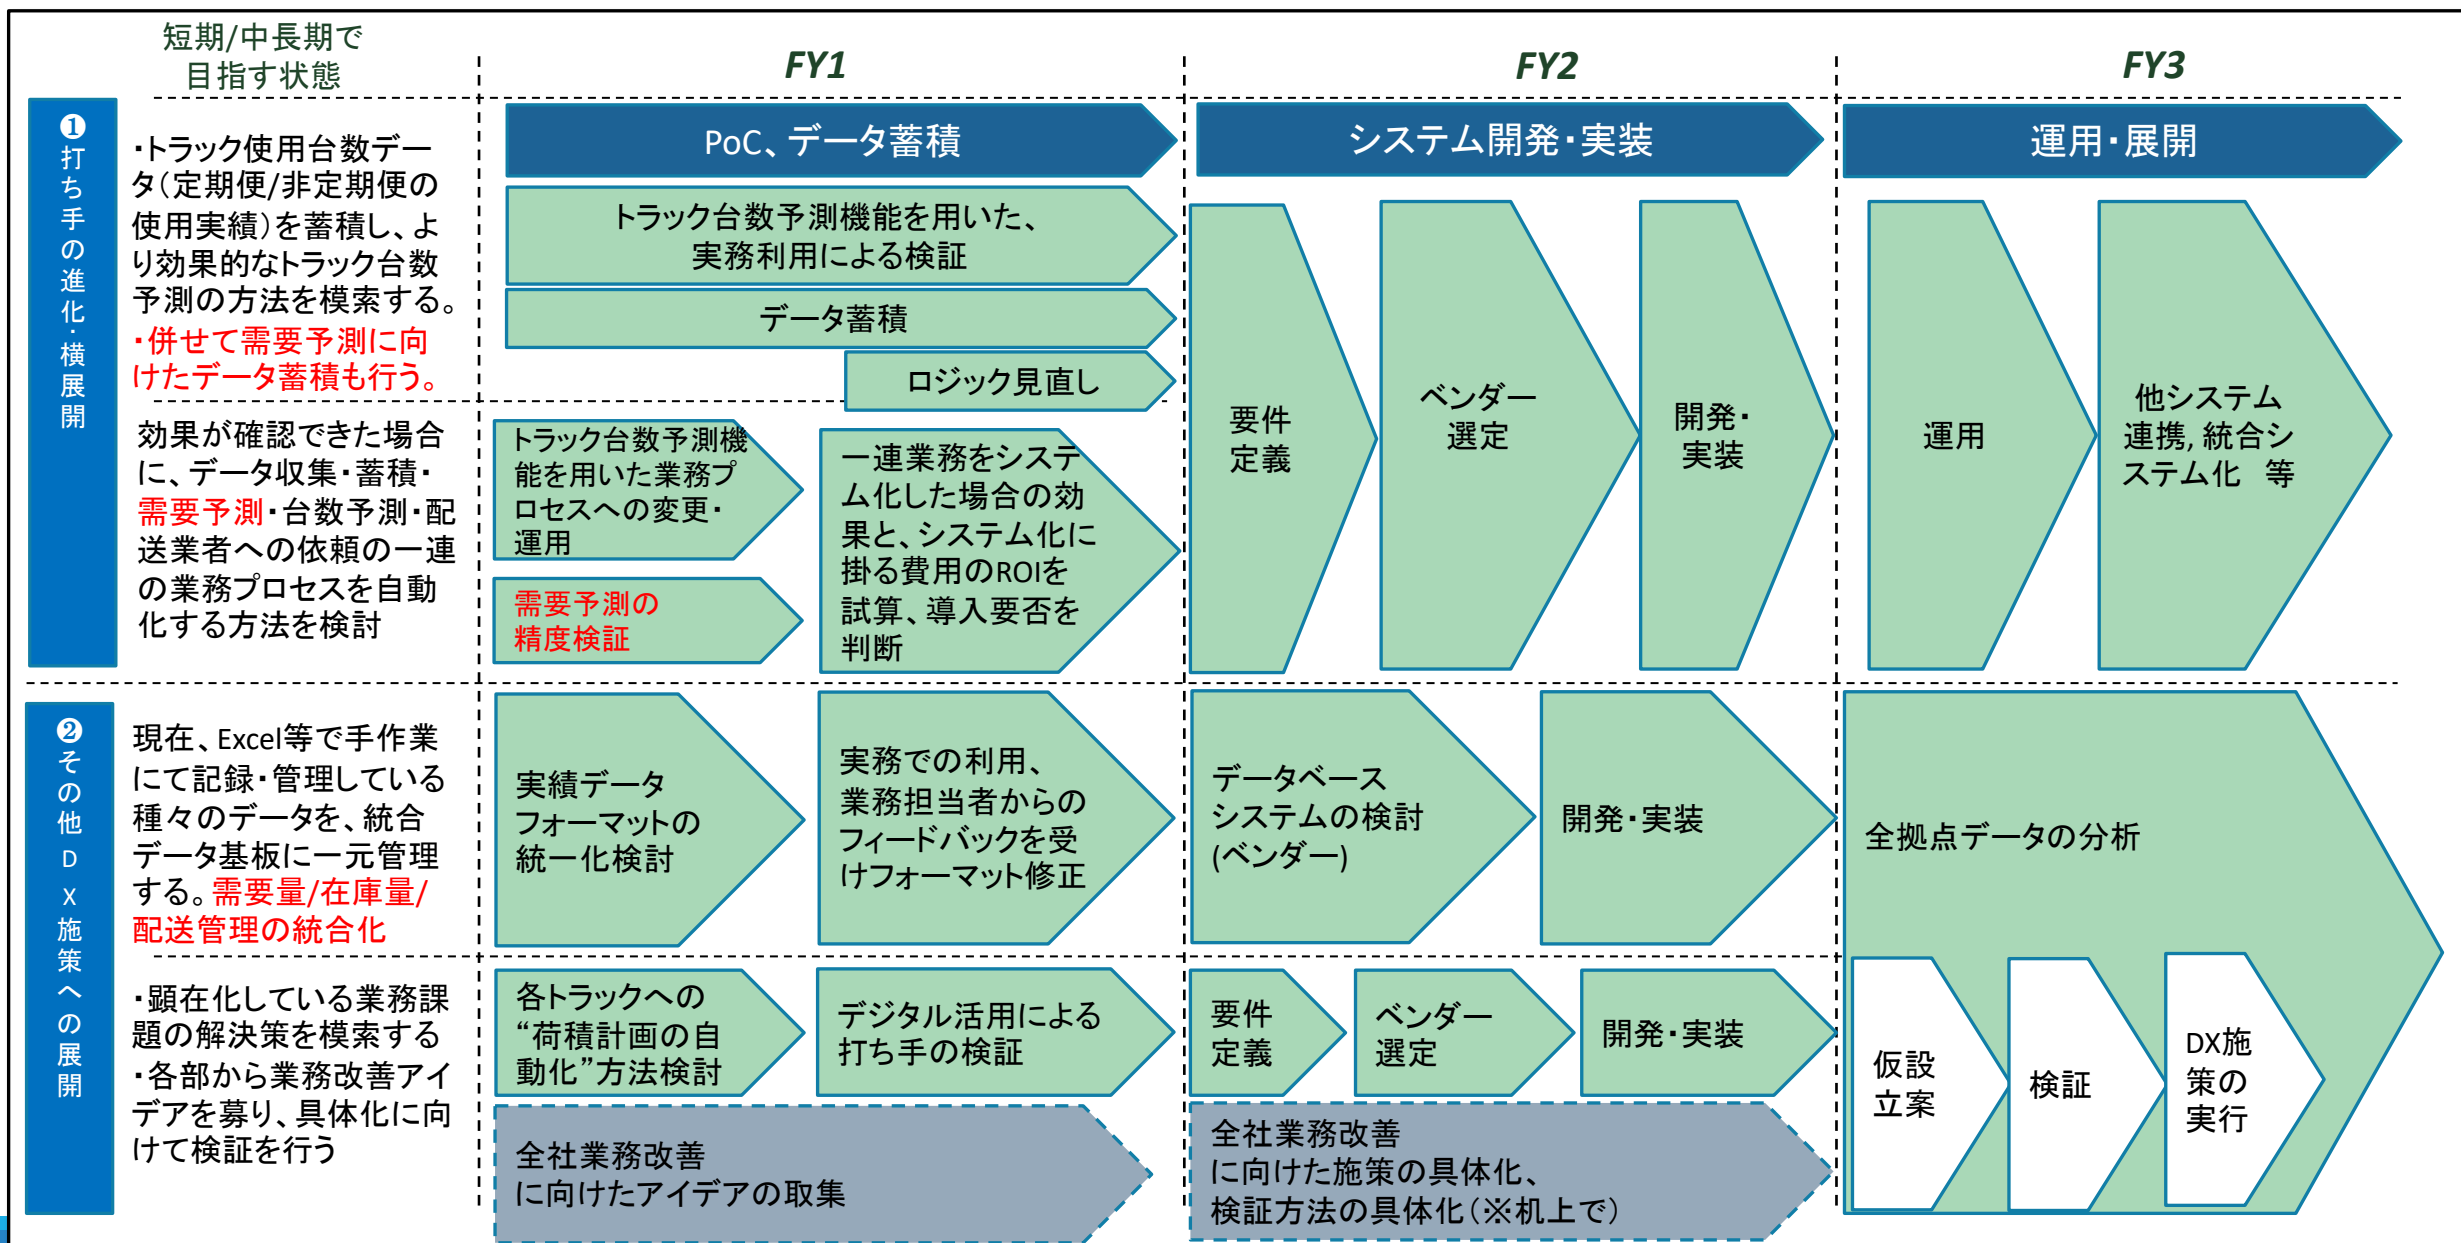




§ 7. ロードマップの策定

§ 7-1. DX導入・展開ロードマップの策定

21



統合管理システム:MAEBASI-NET

将来的には、こういった統合システムの構築も可能です

需要予測システム:MAEBASI-DF
(Demand Forecast)

生産管理システム:MAEBASI-PM
(Production Management)

配送管理システム:MAEBASI-DM
(Delivery Management)

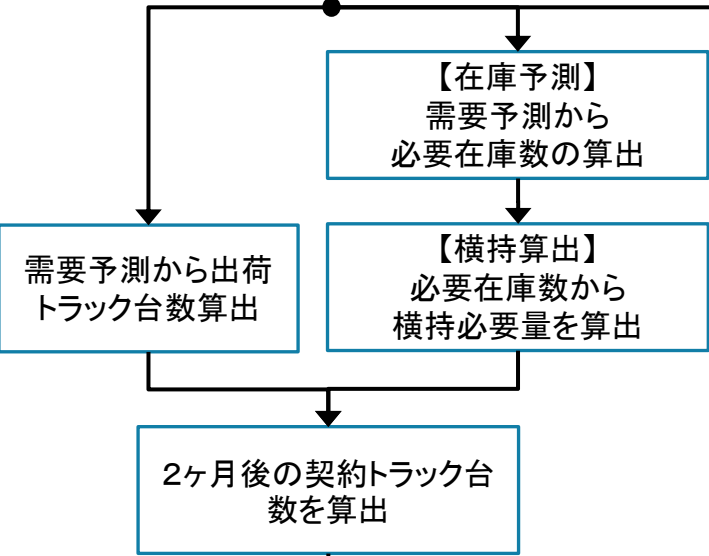
2ヶ月先の需要予測
(過去の最終確定需要量を元に算出。欠品リスク回避の為、内示量より上方で修正)

順次展開

順次展開

システム上で
部品/個数/配送元倉庫/格納先/配送トラックを
事前スケジュールリング

自社



需要予測からどの部品を
何個製造するか算出

部品製造

製造した部品のロット番号
及び保管倉庫をシステムに登録/保管
(QRコードの自動貼付けが望ましい)

在庫予測から
横持が必要な場合は
横持移動(配送システムと連携)

非定期便
要否判定

要

非定期便発注

定期便

非定期便

システムより
配送データを取得

リストを元に配送部品の仕分け
(QRコード自動読込が望ましい。)
(自動コンベア化が出来ると尚良い)

ドライバーに配送リストを配布

トラック積み込み/配送













外注
運送会社



§ 8. 参考資料 (Appendix)









[参考1]パーツタイプ毎の需要量Top3①

24



[参考1]パーツタイプ毎の需要量Top3②

25



予測手法一覧

予測手法	メリット	デメリット
ルールベース	<ul style="list-style-type: none">• データが少なくても予測可能。• なぜそのような予測をしたのかの解釈が容易• 他の手法と違い機械学習技術を必要としないため、比較的簡単に導入することができる。	<ul style="list-style-type: none">• 人間がルールを決めてあげる必要がある。• 事前に設定したルールのみに従って動くため、変化に弱い。
AI・機械学習モデル	<ul style="list-style-type: none">• 一般的にはルールベースよりも精度が高い（データ量が十分に有る場合に限る）	<ul style="list-style-type: none">• パターンを見つけられるだけの十分な量のデータが必要• なぜそのような予測をしたのかの解釈が難しい場合がある• 運用コストが比較的高い
時系列モデル	<ul style="list-style-type: none">• 予測したい項目(今回の場合トラック台数)のデータだけで予測が可能• 一般的にはルールベースよりも精度が高い	<ul style="list-style-type: none">• トレンドや季節性が現れる十分な量のデータが必要

※データ量から考えて、今回はルールベースを採用する

ご清聴ありがとうございました

End of Document
